

Transfer Learning(전이학습)

1. 전이학습에 대하여

전이 학습은 높은 정확도를 비교적 짧은 시간 내에 달성할 수 있기 때문에 컴퓨터 비전 분야에서 유명한 방법론 중 하나이다. 전이학습을 이용하면, 이미 학습한 문제와 다른 문제를 풀 때에도, 밑바닥에서부터 모델을 쌓아올리는 대신에 이미 학습되어있는 패턴들을 활용해서 적용시킬 수 있다.

컴퓨터 비전에서 말하는 전이학습은 주로 **사전학습 된 모델(pre-trained model)**을 이용하는 것을 뜻한다. 사전학습 된 모델이란, 내가 풀고자 하는 문제와 비슷하면서 사이즈가 큰 데이터로 이미 학습이 되어 있는 모델이다. 그런 큰 데이터로 모델을 학습시키는 것은 오랜 시간과 연산량이 필요하므로, 관례적으로는 이미 공개되어있는 모델들을 그저 import해서 사용한다(ex. VGG, Inception, MobileNet). 사전학습 모델들의 ImageNet 이미지 분류 대회에 대한 성능은 Canziani et al. (2016) 논문에 전반적으로 정리되어있다.

2. CNN, 합성곱 신경망

전이학습에 이용되는 몇몇의 사전 학습 모델들은 큰 사이즈의 **합성곱 신경망(Convolutional Neural Networks, CNN)** 구조를 가지고 있습니다 (Voulodimos et al. 2018). 일반적으로, CNN은 다양한 컴퓨터 비전 문제에서 뛰어난 성능을 보여주는 것으로 나타났습니다 (Bengio 2009). CNN이 받은 최근 몇 년 간의 뜨거운 관심은 **좋은 성능**과, 동시에 **학습을 쉽게 할 수 있다**는 두 가지 메인 요소가 있었기 때문입니다.

일반적인 CNN은 다음 두 가지 파트로 구성되어 있습니다.

아래 그림은 CNN을 기반으로 하는 모델의 구조를 나타낸 것입니다.이 그림은 설명을 위해 간소화시켜서 나타낸 것입니다. 실제 모델은 당연히 이것보다 훨씬 복잡하게 이루어져 있습니다!

- **Convolutional base**

합성곱층과 풀링층이 여러겹 쌓여있는 부분입니다. convolutional base의 목표는 **이미지로부터 특징을 효과적으로 추출하는 것 (feature extraction)** 입니다. 합성곱층과 풀링층에 대한 직관적인 설명을 보시려면 Chollet (2017) 논문을 참고하세요.

◦ Classifier

주로 완전 연결 계층 (fully connected layer)로 이루어져 있습니다. 완전 연결 계층이란 모든 계층의 뉴런이 이전 층의 출력 노드와 하나도 빠짐없이 모두 연결되어 있는 층을 말합니다. 분류기(Classifier)의 최종 목표는 **추출된 특징을 잘 학습해서 이미지를 알맞은 카테고리로 분류하는 것 (image classification)** 입니다.



이러한 딥러닝 모델의 중요한 성격 중 하나는 바로 **"계층적인 특징"을 "스스로" 학습한다**는 점입니다. **계층적인 특징을 학습한다** 는 말이 무슨 뜻이냐면, 모델의 **첫 번째 층**은 **"일반적인 (general)"** 특징을 추출하도록 하는 학습이 이루어지는 반면에, 모델의 **마지막 층**에 가까워질수록 특정 데이터셋 또는 특정 문제에서만 나타날 수 있는 **"구체적인(specific)"** 특징을 추출해내도록 하는 고도화된 학습이 이루어진다는 뜻입니다. 따라서 앞단에 있는 계층들은 다른 데이터셋의 이미지들을 학습할 때도 재사용될 수 있지만, **뒷단의 계층들은 새로운 문제를 맞이할 때마다 새로 학습이 필요합니다.**

Yosinski et al. (2014) 논문에서는 이러한 딥러닝의 특성에 대해, '만약 첫 번째 계층에서 추출된 특징이 **일반적인** 특징이고 마지막 층에서 추출된 특징이 **구체적인** 특징이라면, 네트워크 내의 어딘가에 일반적인 수준에서 구체적인 수준으로 넘어가는 **전환점**이 분명 존재할 것이다.' 라고 서술하고 있습니다.

결론적으로, 우리가 살펴본 CNN 모델의 **Convolutional base** 부분, 그 중에서도 특히 **낮은 레벨의 계층**(input에 가까운 계층)일수록 **일반적인 특징**을 추출할 것이고, 그와 반대로 **Convolutional base**의 **높은 레벨의 계층**(output에 가까운 계층)과 **Classifier** 부분은 보다 **구체적이고 특유한 특징**들을 추출할 것입니다.

3. 사전에 학습된 모델을 내 프로젝트에 맞게 재정의하기

사전 학습된 모델을 이제 나의 프로젝트에 맞게 재정의한다면, 먼저 **원래 모델에 있던 classifier를 없애는 것**으로 시작한다. 원래의 classifier는 삭제하고, **내 목적에 맞는 새로운 classifier를 추가**한다.

그 후 마지막으로 새롭게 만들어진 나의 모델을 다음 세 가지 전략중 한 가지 방법을 이용해 **파인튜닝(fine-tuning)**을 진행한다.

파인튜닝이란?

기존에 학습되어져 있는 모델을 기반으로 아키텍처를 새로운 목적(나의 이미지 데이터에 맞게)변형하고 이미 학습된 모델 Weights로 부터 학습을 업데이트하는 방법

전략 1 : 전체 모델을 새로 학습시키기

이 방법은 사전학습 **모델의 구조만** 사용하면서, 내 데이터셋에 맞게 전부 새로 학습시키는 방법이다. 모델을 밑바닥에서부터 새로 학습시키는 것이므로, 큰 사이즈의 데이터셋이 필요하다.

전략 2 : Convolutional base의 일부분은 고정시킨 상태로, 나머지 계층과 classifier를 새로 학습시키기

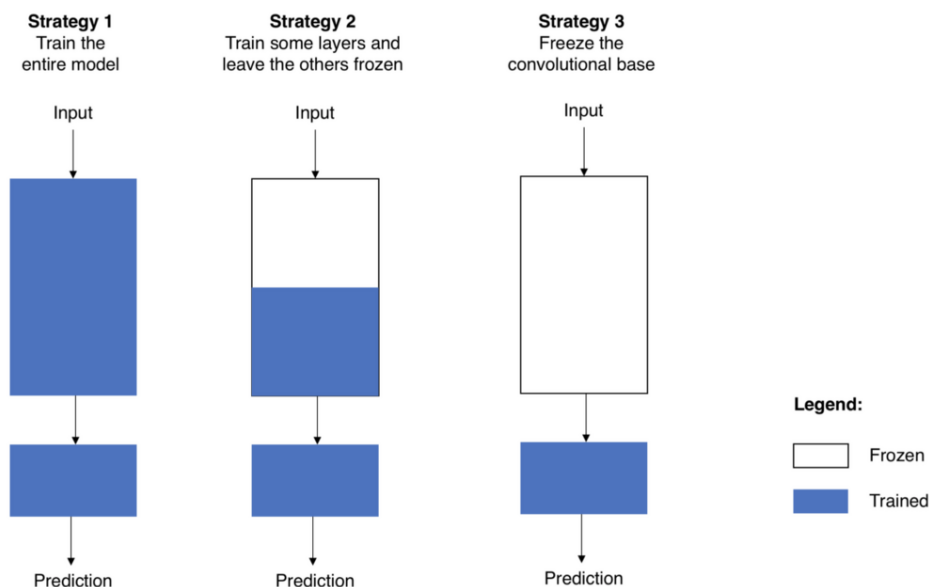
앞서 언급했듯이, 낮은 레벨의 계층은 일반적인 특징(어떤 문제를 푸느냐에 상관 없이 독립적인 특징)을 추출하고, 높은 레벨의 계층은 구체적이고 특유한 특징(문제에 따라 달라지는 특징)을 추출한다. 이런 특성을 이용해서, 우리는 신경망의 파라미터 중 **어느 정도까지를 재학습시킬지**를 정할 수 있다.

주로, 만약 **데이터셋이 작고 모델의 파라미터가 많다면**, 오버피팅이 될 위험이 있으므로 더 많은 계층을 건들지 않고 그대로 둔다. 반면에, **데이터셋이 크고 그에 비해 모델이 작아서 파**

라미터가 적다면, 오버피팅에 대한 걱정을 할 필요가 없으므로 **더 많은 계층을 학습시켜서** 내 프로젝트에 더 적합한 모델로 발전시킬 수 있다.

전략 3 : Convolutional base는 고정시키고, classifier만 새로 학습시키기

이 경우는 보다 극단적인 상황일 때 생각할 수 있는 케이스이다. Convolutional base는 건들지 않고 그대로 두면서 **특징 추출 메커니즘으로써 활용**하고, **classifier만 재학습**시키는 방법을 쓴다. 이 방법은 컴퓨팅 연산 능력이 부족하거나 데이터셋이 너무 작을때 또는 내가 풀고자 하는 문제가 사전학습모델이 이미 학습한 데이터셋과 매우 비슷할 때 고려해볼 수 있다.



비교적 간단히 사용할 수 있는 세 번째 전략과 다르게, 첫 번째와 두 번째 전략은 learning rate에 대해서 조심해야 할 필요가 있다. learning rate는 신경망에서 **파라미터를 얼마나 재조정할 것인지**를 결정하는 하이퍼 파라미터이다. CNN 베이스의 사전학습 모델을 사용할 때에는, 이전에 학습한 내용들을 모두 잊어버릴 위험이 있기 때문에 **작은 learning rate**를 사용하는 것이 바람직하다. 사전학습 모델이 잘 학습되었다는 가정하에, 작은 learning rate으로 학습을 시킨다면 CNN모델의 파라미터들을 너무 빠르게, 혹은 너무 많이 왜곡시키지 않고 원래 학습되어있던 지식을 잘 보존하면서 추가로 학습을 해 나갈 것이다.

4. References

<https://jeinalog.tistory.com/13>